Sebastian Herrera Claro

CIENTÍFICO DE DATOS · INGENIERO DE SISTEMAS

Cartagena, Colombia sebastianherrerajr@gmail.com +57 318 802 2279 soushiki.github.io/data-science
github.com/soushiki LinkedIn

PERFIL

Ingeniero de sistemas enfocado en ciencia de datos. Desarrollo proyectos completos con datos públicos en vivo: ingesta desde APIs, limpieza, modelado, evaluación rigurosa y dashboards interactivos. Mi trabajo abarca clasificación, pronóstico de series de tiempo y pruebas A/B / inferencia causal, y mi experiencia en desarrollo de software me ayuda a construir pipelines reproducibles. Me importan las variables sin fuga de información, la validación fuera de tiempo y las recomendaciones accionables para el negocio, incluso "no desplegar el modelo" cuando los datos lo indican.

PROYECTOS DE CIENCIA DE DATOS

Prueba A/B de Campaña de Email y Modelos de Uplift

Dashboard · Código

Python · SciPy · statsmodels · scikit-learn

- Analicé un experimento aleatorizado de email con 3 grupos y 64 mil clientes: verifiqué la aleatorización (tamaño de los grupos y balance de covariables) y luego apliqué intervalos de confianza bootstrap, corrección de Holm por pruebas múltiples, reducción de varianza tipo CUPED y análisis de potencia.
- Demostré que el email de hombres aumentó las visitas un **72%** y generó **US$131 por cada 1.000 envíos (IC 95% US$46–216)**. Encontré que el email de mujeres solo funciona con compradoras de esa línea.
- Comparé modelos de uplift S-, T- y X-learner en 20 particiones remuestreadas, más evaluación de políticas offline, y recomendé **no** desplegar la segmentación por modelo porque no superó en ganancia a una regla simple.

Pronóstico de Demanda Eléctrica de Gran Bretaña

Dashboard · Código

Python · pandas · scikit-learn · NESO & Open-Meteo APIs

- Pronostiqué la demanda eléctrica nacional cada media hora con un día de anticipación y un **MAPE de 4,2%**, la mitad del error de un modelo estacional ingenuo, usando *pronósticos* meteorológicos archivados y una verificación automática de fuga de información.
- Comparé el modelo con los pronósticos oficiales del operador de red durante 463 días no vistos. El modelo perdió en demanda pico (error de 802 vs. 578 MW), pero una combinación fija 50/50 **superó al operador en 6,7%** porque los dos pronósticos se equivocan en direcciones opuestas.
- Calibré intervalos de predicción del 80% con ajuste conformal, aumentando la cobertura empírica de 59% a 79%.

Predicción de Retrasos en Solicitudes 311 de Nueva York

Dashboard · Código

Python · pandas · scikit-learn · Socrata API

- Construí un pipeline completo con ~400 mil solicitudes de servicio de Nueva York desde la API de datos abiertos de la ciudad, con reglas de calidad de datos documentadas y variables limitadas a la información disponible al momento de registrar cada solicitud.
- Descubrí que un modelo con ROC-AUC de 0,95 apenas superaba una tabla de consulta por tipo de queja, y replanteé el objetivo a "más lenta que solicitudes similares". Con ese objetivo el modelo alcanza un **lift de 2,2×**: el 64% de sus alertas del 10% superior se retrasan, frente a una tasa base del 29%.
- Validé el modelo en un mes futuro reservado y publiqué un dashboard interactivo que explica un factor de confusión según la hora del día.

HABILIDADES

Programación y datos	Python (pandas, NumPy), SQL (PostgreSQL, MySQL), MongoDB, REST APIs
Machine learning	scikit-learn, gradient boosting, regularized regression, uplift models (S/T/X-learners), ingeniería de variables, validación temporal
Estadística	SciPy, statsmodels, pruebas A/B, bootstrap, corrección por pruebas múltiples, análisis de potencia, CUPED, intervalos de predicción
Visualización	matplotlib, dashboards interactivos SVG/HTML
Ingeniería	Git, GitHub Pages, JavaScript, React, Node.js, Java, C++
Idiomas	Español (nativo) · Inglés (C2)

EDUCACIÓN

Ingeniería de Sistemas · Universidad de Cartagena — Mar 2019 – Dic 2024